

# Методы детектирования аномалий.

## Лекция 5: Линейные модели


Иван Шанин  
`ivan.shanin@gmail.com`

ИПИ РАН


18.03.2019

# Регрессионные модели

- ▶ **Предположение:** датасет на самом деле лежит в линейном подпространстве меньшей размерности
- ▶ Подобное предположение осмысленно при наличии ярко выраженной мультиколлинарности в задаче
- ▶ А также при наличии неинформативных признаков



(a) View 1 (*Autompg*)



(b) View 2 (*Autompg*)

# Линейные регрессионные модели

- ▶ Выразим признак  $y$  через зависимые переменные:

$$y = \sum_{i=1}^d w_i \cdot x_i + w_{d+1}$$

- ▶ Найдем параметры  $w_1 \dots w_{d+1}$  при помощи обучающей выборки  $\overline{X_1} \dots \overline{X_N}$
- ▶ Тогда для каждого объекта  $\overline{X_j}$  вычисляется **ошибка**  $\epsilon_j$  смоделированного признака  $y$ :

$$y_j = \sum_{i=1}^d w_i \cdot x_{ij} + w_{d+1} + \epsilon_j$$

- ▶ Суммарный квадрат ошибки  $\sum_{j=1}^N \epsilon_j^2$  можно использовать как функционал качества задачи регрессии (регрессия методом наименьших квадратов)
- ▶ Значение ошибки на конкретном объекте является показателем аномальности объекта

# Матричная постановка задачи

- ▶ составим матрицу  $D$  размерности  $N \times d + 1$  из строк  $(x_{j1}, \dots, x_{jd}, 1)$
- ▶ также составим вектор весов  $\overline{W}$  и вектор значений признака  $\overline{y}$
- ▶ задачу нахождения вектора  $\overline{W}$  можно записать следующей системой уравнений

$$\overline{y} \approx D\overline{W}^T$$

$$\|D\overline{W}^T - \overline{y}\|^2 \rightarrow \min \Rightarrow 2D^T D\overline{W}^T - 2D^T \overline{y} = 0 \Rightarrow$$

$$\overline{W}^T = (D^T D)^{-1} D^T \overline{y}$$


- ▶ Таким образом, для нахождения оптимального набора параметров  $\overline{W}$  необходимо обратить матрицу  $D^T D$

# Гребневая регуляризация

- ▶ Для борьбы с недоопределенностью используется регуляризатор:

$$J = \|D\bar{W}^T - \bar{y}\|^2 + \alpha\|W\|^2 \rightarrow \min_{\bar{W}}$$

- ▶  $2(D^T D + \alpha I)\bar{W}^T - 2D^T \bar{y} = 0 \Rightarrow \bar{W}^T = (D^T D)^{-1} D^T \bar{y}$
- ▶ Полученный показатель аномальности будет зависеть от выбора моделируемого признака



# Principal Component Analysis: постановка задачи

- ▶ Рассмотрим выборку

$$F_{L \times N} = \begin{bmatrix} f_1(x_1) & \dots & f_N(x_1) \\ \dots & \dots & \dots \\ f_1(x_L) & \dots & f_N(x_L) \end{bmatrix} = \begin{bmatrix} x_1 \\ \dots \\ x_L \end{bmatrix}$$

- ▶ Обозначим через  $z_i = g_1(x_i), \dots, g_M(x_i)$  признаковые описания тех же объектов в новом пространстве размерности  $M < N$

$$G_{L \times M} = \begin{bmatrix} g_1(x_1) & \dots & g_M(x_1) \\ \dots & \dots & \dots \\ g_1(x_L) & \dots & g_M(x_L) \end{bmatrix} = \begin{bmatrix} x_1 \\ \dots \\ x_L \end{bmatrix}$$

- ▶ Определим матрицу линейного преобразования  $U = (u_{js})_{N \times M}$ :

$$\hat{f}_j(x) = \sum_{s=1}^M g_s(x) u_{js}$$

# Метод главных компонент


- ▶ Будем искать одновременно матрицы  $G$  и  $U$ , минимизируя суммарную невязку смоделированных признаков

$$\Delta^2(G, U) = \sum_{i=1}^L \|\hat{x}_i - x_i\|^2 = \sum_{i=1}^L \|z_i U^T - x_i\|^2 = \|GU^T - F\|^2 \rightarrow \min_{G, U}$$

## Теорема (PCA)


Если  $m \leq \text{rank } F$ , то минимум  $\Delta^2(G, U)$  достигается, когда столбцы матрицы  $U$  есть собственные векторы  $F^T F$ , соответствующие  $m$  максимальным собственным значениям. При этом  $G = FU$ , матрицы  $U$  и  $G$  ортогональны

# Метод главных компонент







# Автоэнкодеры




(a) Perceptron



(b) Multilayer




# Автоэнкодеры и матричная факторизация



OUTLIER SCORES IN ENTRIES OF  $D - D^I = D - UV^T$

(a) Matrix factorization



OUTLIER SCORES IN ENTRIES OF  $D - D^I = D - (\psi \circ \phi)(D)$

(b) Autoencoder